

PageRank, HITS i SALSA

poređenje algoritama za rangiranje čvorova u usmerenim grafovima

Nenad Dobrosavljević

Naučno izračunavanje, školska 2025/26.
Matematički fakultet, Univerzitet u Beogradu

Tema sa spiska: *HITS i SALSA algoritmi za rangiranje čvorova u usmerenim grafovima /
poređenje sa PageRank algoritmom*

Kod projekta: repozitorijum `pagerank-hits-salsa-comparison`
<https://github.com/dobrosavljevicnenad/pagerank-hits-salsa-comparison>

August 10, 2026

Contents

Sažetak	2
1 Uvod	3
1.1 Istraživačke hipoteze	3
1.2 Struktura rada	3
2 Teorijska osnova	4
2.1 PageRank	4
2.2 HITS	4
2.3 SALSA	4
2.4 Metodologija poređenja	5
3 Skup podataka	6
3.1 Osnovna struktura	6
4 Implementacija i validacija	7
4.1 PageRank	7
4.2 HITS	8
4.3 SALSA	9
5 Rezultati poređenja	12
5.1 Rang-korelacije	12
5.2 Preklapanje top- k skupova	12
5.3 Udeo „ugašenih” skorova	13
5.4 Test hipoteze H3	13
6 Zaključak	15
6.1 Sažetak nalaza po hipotezama	15
6.2 Diskusija	15
6.3 Zaključak	15

Sažetak

Ovaj rad implementira i poredi tri poznata algoritma za rangiranje čvorova u usmerenim grafovima – **PageRank**, **HITS** i **SALSA** – primenjene globalno nad istim usmerenim grafom (web-Stanford, 281.903 čvora, 2.312.497 grana). Sve tri implementacije su napisane od nule nad retkim (sparse) matricama i validirane: PageRank i HITS poređenjem sa **networkx**, a SALSA preko poznatog teorijskog rezultata sa jedne povezane komponente. Pošto ne postoje ljudske relevance labele (za razliku od referentnog rada Najork-a [6]), rangiranja poredimo međusobno preko rang-korelacije (Spearman, Kendall τ) i preklapanja top- k skupova, metodologijom inspirisanom radom Borodin et al. [7]. Postavljene su i testirane tri hipoteze: (H1) SALSA-in autoritet skor je blizak ulaznom stepenu čvora; (H2) HITS "gasi" (svodi na nulu) znatno više čvorova od SALSA-e i PageRank-a; (H3) HITS i SALSA, uprkos radu nad identičnim grafom, daju slabo korelisana rangiranja. Sve tri hipoteze su potvrđene, pri čemu je H3 potvrđena znatno izraženije nego što je pretpostavljeno – rang-korelacija između HITS-a i SALSA-e je praktično nula (Spearman $\rho \approx -0,02$), a HITS je nekorelisan i sa PageRank-om ($\rho \approx -0,07$).

1 Uvod

Jedan od osnovnih problema u obradi velikih grafova (a posebno veb-grafa) jeste rangiranje njegovih čvorova po nekoj meri "važnosti". **PageRank** [5] je algoritam koji stoji iza originalnog rangiranja rezultata Google pretrage, i modeluje važnost stranice kao stacionarnu verovatnoću slučajnog šetača po grafu hiperlinkova. **HITS** [2] je nezavisno predložen algoritam koji za svaki čvor računa dva skora – *hub* (koliko dobro čvor upućuje na kvalitetan sadržaj) i *authority* (koliko je čvor sam kvalitetan izvor) – preko iterativnog "uzajamnog pojačavanja". **SALSA** [4] kombinuje ideje oba prethodna algoritma: koristi istu podelu na hub/authority skorove kao HITS, ali ih računa preko dve nezavisne stohastičke šetnje, na način bliži PageRank-u.

Ideja ovog projekta je da se sva tri algoritma implementiraju nad *istim* usmerenim grafom i uporede dobijena rangiranja. Za razliku od originalnih radova o HITS-u i SALSA-i, koji ove algoritme definišu kao *query-dependent* (operišu nad malim "neighborhood graph"-om izgrađenim oko rezultata pretrage za dati upit), mi ih primenjujemo **globalno**, nad celim grafom – u skladu sa formulacijom teme ("rangiranje čvorova", a ne "rangiranje rezultata pretrage"). Ovo je matematički legitimna primena istih algoritama: base set postaje ceo skup čvorova, a neighborhood graph ceo graf, samo bez query-specifičnog filtriranja.

Ova primena je istovremeno i inspirisana i uporediva sa radom Marc-a Najork-a [6], koji je HITS i SALSA uporedio na velikom veb-grafu (463 miliona stranica) i skupu od 28.043 upita sa ljudski ocenjenim rezultatima, koristeći IR metrike MAP, MRR i NDCG. Mi nemamo pristup relevance labelama niti upitima te veličine, pa umesto IR metrika rangiranja poredimo međusobno – preko rang-korelacije i preklapanja top-*k* skupova – metodologijom koju je za sličnu svrhu koristio i Borodin et al. [7].

1.1 Istraživačke hipoteze

Na osnovu teorijskih svojstava algoritama (sekcija 2), postavljene su tri hipoteze:

- **H1** – Na grafu koji je (skoro) jedna komponenta povezanosti, SALSA-in autoritet skor treba da bude blizak proporcionalnosti sa ulaznim stepenom (in-degree) čvora – poznat teorijski rezultat iz [4] – dok HITS to svojstvo nema.
- **H2** – HITS, kao power-iteracija ka jednom dominantnom sopstvenom vektoru, "gasi" (svodi na skor ≈ 0) znatno veći udeo čvorova od SALSA-e i PageRank-a, koji imaju ugrađene mehanizme (stohastička normalizacija, odnosno teleportacija) koji to sprečavaju.
- **H3** – HITS i SALSA, uprkos tome što u našoj globalnoj varijanti operišu nad istim grafom, mogu proizvesti rangiranja koja su slabije korelisana nego što bi se intuitivno očekivalo – analogno zapažanju iz [6] da SALSA znatno nadmašuje HITS uprkos istom neighborhood graph-u.

1.2 Struktura rada

Sekcija 2 daje teorijsku pozadinu i formalne definicije sva tri algoritma i metodologije poređenja. Sekcija 3 opisuje skup podataka i njegovu strukturnu analizu. Sekcija 4 opisuje implementaciju i validaciju svakog algoritma pojedinačno. Sekcija 5 donosi rezultate direktnog poređenja i testiranje hipoteza. Sekcija 6 sumira nalaze i povezuje ih sa referentnom literaturom. Ceo kod projekta (Jupyter sveske, numerisane 01–07) dostupan je u pratećem repozitorijumu.

2 Teorijska osnova

Neka je veb predstavljen usmerenim grafom (V, E) , gde su čvorovi V stranice, a usmerena grana $(u, v) \in E$ predstavlja hiperlink sa stranice u ka stranici v . Sa $\text{out}(u)$ i $\text{in}(u)$ označavamo, redom, izlazni i ulazni stepen čvora u , a sa $n = |V|$ broj čvorova.

2.1 PageRank

PageRank [5] modeluje "slučajnog šetača" koji sa verovatnoćom d (damping faktor) prati nasumično izabranu izlaznu granu trenutne stranice, a sa verovatnoćom $1 - d$ "teleportuje" se na potpuno slučajnu stranicu. Skor stranice u je stacionarna verovatnoća da se šetač u datom trenutku nalazi na u :

$$R(u) = \frac{1-d}{n} + d \sum_{v: (v,u) \in E} \frac{R(v)}{\text{out}(v)} \quad (1)$$

Koristi se standardna vrednost $d = 0,85$. Čvorovi bez izlaznih grana ("dangling" čvorovi, $\text{out}(u) = 0$) tretiraju se posebno: njihova masa se ravnomerno redistribuira na sve čvorove grafa, čime se očuva $\sum_u R(u) = 1$. Jednačina (1) se rešava metodom stepenovanja (power-iteracijom) nad retkom matricom susedstva.

2.2 HITS

HITS [1, 2] za svaki čvor u računa *authority* skor $A(u)$ (koliko je u dobra referenca) i *hub* skor $H(u)$ (koliko u dobro upućuje na autoritativne stranice), preko iterativnog "uzajamnog pojačavanja":

$$A'(v) = \sum_{(u,v) \in E} H(u), \quad H'(u) = \sum_{(u,v) \in E} A(v) \quad (2)$$

nakon čega se oba vektora normalizuju na jediničnu L_2 normu. U matričnom obliku (M – matrica susedstva), $a' = M^T h$ i $h' = M a$ – što je tačno power-iteracija ka dominantnim singularnim vektorima matrice M (ekvivalentno: a konvergira ka glavnom sopstvenom vektoru $M^T M$, a h ka glavnom sopstvenom vektoru $M M^T$).

Ovo svojstvo je značajno: power-iteracija po konstrukciji konvergira *samo* ka pravcu koji odgovara najvećoj sopstvenoj vrednosti. Ako graf ima više nezavisnih komponenti, globalna iteracija bira jednu, sa najvećom sopstvenom vrednošću, dok sve ostale asimptotski dobijaju skor $\rightarrow 0$ (motivacija za hipotezu H2).

2.3 SALSA

SALSA [3, 4] računa authority i hub skorove preko **dve nezavisne stohastičke šetnje** na bipartitnom hub-authority grafu:

$$H'(u) = \sum_{(u,v) \in N} \sum_{(w,v) \in N} \frac{H(w)}{\text{in}(v) \cdot \text{out}(w)}, \quad A'(u) = \sum_{(v,u) \in N} \sum_{(v,w) \in N} \frac{A(w)}{\text{out}(v) \cdot \text{in}(w)} \quad (3)$$

Intuitivno: hub-šetnja ide hub $w \rightarrow$ nasumičan authority-sused v (verovatnoća $1/\text{out}(w)$) $\rightarrow$ nasumičan hub u koji takođe pokazuje na v (verovatnoća $1/\text{in}(v)$). Authority-šetnja je simetrična, u obrnutom smeru.

Poznat teorijski rezultat [4]: ako je graf (u odgovarajućem bipartitnom smislu) jedna povezana komponenta, ove šetnje imaju jedinstvenu stacionarnu raspodelu $A(u) \propto \text{in}(u)$ i $H(u) \propto \text{out}(u)$ – SALSA se svodi na normalizovan stepen čvora (motivacija za hipotezu H1).

2.4 Metodologija poređenja

Pošto ne raspoložemo relevance labelama, rangiranja poredimo direktno preko:

- **Spearman-ove rang-korelacije** ρ i **Kendall-ovog** τ – standardnih mera slaganja dva rangiranja, korišćenih u istu svrhu (poređenje algoritama bez ground-truth-a) u [7];
- **preklapanja top- k skupova** čvorova za nekoliko vrednosti k ;
- udela čvorova čiji je skor praktično jednak nuli (ispod 10^{-10}), kao direktne mere "gašenja" iz hipoteze H2.

Kao baseline karakteristike (analogno [6, 7]) koristimo i sirov ulazni i izlazni stepen čvora (in-degree, out-degree).

3 Skup podataka

Korišćen je graf **web-Stanford**¹ (Stanford Network Analysis Project, SNAP) – usmereni graf hiperlinkova između stranica sa domena `stanford.edu`, prikupljen 2002. godine. Dataset sadrži $n = 281.903$ čvora i $m = 2.312.497$ usmerenih grana, bez dupliranih grana. Graf se preuzima automatski i keš-uje lokalno; nije deo repozitorijuma zbog veličine.

3.1 Osnovna struktura

Tabela 1 sumira osnovne strukturne osobine grafa, dobijene analizom u prvoj svesci projekta.

Table 1: Osnovne strukturne karakteristike grafa web-Stanford.

Karakteristika	Vrednost
Broj čvorova	281.903
Broj grana	2.312.497
Gustina ($m/n(n-1)$)	$2,91 \times 10^{-5}$
Prosečan in/out-degree	8,2
Maksimalni in-degree	38.606
Maksimalni out-degree	255
Čvorovi sa out-degree = 0 (dangling)	172 (0,06%)
Čvorovi sa in-degree = 0	20.315 (7,2%)
Slabo povezane komponente (broj / najveća)	365 / 90,6% čvorova
Jako povezane komponente – SCC (broj / najveća)	29.914 / 53,4% čvorova

Distribucija stepena čvorova (slika 1) potvrđuje očekivano *power-law* ponašanje, tipično za veb-grafove: velika većina čvorova ima mali stepen, dok mali broj čvorova ima izrazito veliki stepen. Upečatljiva je asimetrija između maksimalnog in-degree-a (38.606) i out-degree-a (svega 255) – upravo ta asimetrija je ono što HITS i SALSA pokušavaju da uhvate razdvajanjem hub i authority uloge.




Figure 1: Distribucija ulaznog i izlaznog stepena čvorova (log-log skala).

Graf pokazuje klasičnu „bowtie” strukturu veb-grafova [8]: dominantna slaba komponenta (90,6% čvorova), ali jako povezana komponenta (SCC) obuhvata svega 53,4% čvorova, uz čak 29.914 sitnih SCC-ova. Graf, dakle, *nije* jedna savršeno povezana komponenta – činjenica direktno relevantna za hipoteze H1 i H2.

¹<https://snap.stanford.edu/data/web-Stanford.html>

4 Implementacija i validacija

Sva tri algoritma implementirana su od nule nad *retkim* (sparse) matricama (`scipy.sparse`), jer bi gusta $n \times n$ matrica za $n=281.903$ zahtevala oko 631 GB memorije. Kod je organizovan kao niz Jupyter svezaka (01–07), svaka posvećena jednoj fazi projekta.

4.1 PageRank

Implementacija prati jednačinu (1), sa dangling-korekcijom implementiranom kao efikasna skalarna korekcija (bez materijalizacije guste korekcionne matrice). Power-iteracija konvergira nakon **118 iteracija** ($\text{tol} = 10^{-10}$), geometrijskom (eksponencijalnom) brzinom – slika 2. Ukupna masa je tačno očuvana ($\sum_u R(u) = 1,000000$).

Validacija. Poređenjem sa `networkx.pagerank` na istom grafu: maksimalna apsolutna razlika skorova $5,85 \times 10^{-7}$, Spearman-ova korelacija rangova 0,999997, top-10 skupovi se poklapaju 100%. Naša implementacija je pritom $\approx 11\times$ brža (1,81s naspram 20,80s, uključujući izgradnju grafa) – rad direktno nad sparse matricom bez opšte-namenske apstrakcije grafa.




Figure 2: PageRank – konvergencija power-iteracije (log skala).




Figure 3: Top-10 čvorova po PageRank skoru.

Top-10 rangiranje (slika 3) pokazuje tri dominantna čvora (skorovi 0,0113 / 0,0093 / 0,0083), nakon čega sledi nagli pad na $\approx 0,0024$ – $0,0030$ za rangove 4–10 – oblik konzistentan sa power-law distribucijom in-degree-a.

4.2 HITS

Implementacija prati jednačinu (2), konvergira nakon **97 iteracija** ($\text{tol} = 10^{-12}$), geometrijskom brzinom slično PageRank-u (slika 4), sa $\|h\|_2 = \|a\|_2 = 1,000000$.




Figure 4: HITS – konvergencija power-iteracije (log skala).

Validacija. Poređenjem sa `networkx.hits`, ograničeno na skorove koji nisu numerički zane-marljivi (objašnjenje ispod): Spearman korelacija 0,999984 (authority) i 0,999997 (hub), sa 100% preklapanjem top-10 skupova u oba slučaja.

Test hipoteze H2. Broj čvorova sa *strogo* nula authority skorom (20.315) tačno odgovara broju čvorova sa in-degree= 0 (matematički očekivano – videti jednačinu (2)). Van tih trivijalnih nula, HITS-ova power-iteracija dodatno „gasi” (skor $< 10^{-10}$) još:

- **63,9%** čvorova po authority skor (naspram 7,2% trivijalnih nula),
- **47,7%** čvorova po hub skor (naspram 0,1% trivijalnih).

Ova razlika u odnosu na trivijalne nule (dodatnih $\approx 57\%$ / $\approx 48\%$) je direktna, merljiva posledica dominacije jednog sopstvenog pravca u power-iteraciji (slika 5), za razliku od PageRank-a, koji teleportacijom garantuje nenula skor svakom čvoru.




Figure 5: HITS – udeo čvorova sa praktično-nula skorom ($< 10^{-10}$).




Figure 6: HITS – top-10 čvorova po authority i hub skor.

Top-10 hub skorovi (slika 6, desno) su međusobno skoro identični (opseg 0,007256–0,007253) – signatura da HITS-ov hub-rang dominira jedna gusto međusobno povezana grupa stranica, nalik „tightly knit community” (TKC) efektu opisanom u [3]. Dodatnom analizom utvrđeno je da među 2.000 najboljih hub skorova postoji svega ≈ 77 razlučivih vrednosti – konkretna potvrda ovog fenomena.

4.3 SALSA

Implementacija prati jednačinu (3). Pošto SALSA ne postoji u `networkx`, implementacija je validirana preko teorijskog rezultata: na ručno konstruisanom grafu od jedne komponente, naš authority vektor *egzakt*no reprodukuje normalizovan in-degree (razlika 0,00, konvergencija u jednoj iteraciji).

Konvergencija. Na stvarnom grafu, numerička konvergencija je znatno sporija nego kod PageRank-a i HITS-a (slika 7) – nakon 2.500 iteracija L1 promena je i dalje $\approx 2 \times 10^{-5}$, bez dostizanja stroge tolerancije. Ipak, provera stabilnosti *rangiranja* (poređenjem stanja na 1.000. i

2.500. iteraciji) pokazuje da se authority rangiranje stabilizuje rano (top-10 identičan, Spearman = 0,9957), dok se hub rangiranje stabilizuje nešto sporije (top-10 preklapanje 6/10, Spearman = 0,9926).




Figure 7: SALSA – konvergencija power-iteracije (log skala); primetno sporija od PageRank-a i HITS-a.

Test hipoteze H1. Na stvarnom grafu, korelacija SALSA authority skora sa in-degree-om je $\rho = 0,788$, a hub skora sa out-degree-om $\rho = 0,764$ (slika 8) – jasna, snažna, ali *ne* skoro-savršena proporcionalnost, za razliku od egzaktnog rezultata na jednoj komponenti. Grafik otkriva zašto: umesto jedne dijagonale, vidi se više paralelnih „traka” na istom stepenu čvora – posledica toga što web-Stanford nije jedna (bipartitno) povezana celina (sekcija 3), pa teorijski rezultat važi tačno samo unutar svake takve celine posebno.




Figure 8: SALSA authority vs. in-degree i SALSA hub vs. out-degree (H1).




Figure 9: SALSA – top-10 čvorova po authority i hub skoru.

H1 je stoga potvrđena, ali nijansirano – egzaktno na jednoj komponenti (validacija), a snažno (ne savršeno) na fragmentisanom stvarnom grafu.

5 Rezultati poređenja

U ovoj sekciji sistematski poredimo rangiranja sva tri algoritma (plus in/out-degree baseline), i eksplicitno testiramo hipotezu H3.

5.1 Rang-korelacije

Slika 10 prikazuje matricu Spearman-ovih korelacija, odvojeno za authority-tipa skorove (PageRank, HITS-authority, SALSA-authority, in-degree) i hub-tipa skorove (HITS-hub, SALSA-hub, out-degree) – PageRank nema hub-analog.




Figure 10: Matrica rang-korelacija (Spearman ρ) između algoritama.

Obrazac je jasan: PageRank, SALSA-authority i in-degree međusobno koreliraju umereno do jako ($\rho = 0,59$ – $0,79$). **HITS je odvojen** od sve tri mere ($\rho = -0,07$ do $0,34$), uključujući skoro-nultu korelaciju sa SALSA-om ($\rho = -0,02$), iako obe operišu nad *identičnim* grafom. Na hub strani, HITS-hub i SALSA-hub koreliraju svega $\rho = 0,13$, dok SALSA-hub i out-degree koreliraju znatno jače ($\rho = 0,76$).

5.2 Preklapanje top- k skupova

Tabela 2 prikazuje preklapanje top- k skupova čvorova za nekoliko vrednosti k (authority-tipa skorovi); slika 11 vizualizuje preklapanje za $k = 100$.

Table 2: Preklapanje top- k skupova čvorova (authority-tipa skorovi), u procentima.

Par algoritama	$k=10$	$k=50$	$k=100$	$k=500$	$k=1000$
PageRank vs. HITS-authority	30,0	20,0	20,0	10,8	7,5
PageRank vs. SALSA-authority	60,0	68,0	60,0	46,2	42,4
PageRank vs. in-degree	40,0	66,0	59,0	43,6	38,9
HITS-authority vs. SALSA-authority	60,0	24,0	18,0	18,0	15,2
HITS-authority vs. in-degree	90,0	30,0	18,0	18,2	15,2
SALSA-authority vs. in-degree	70,0	80,0	95,0	93,0	90,6




Figure 11: Preklapanje top-100 skupova čvorova između algoritama.

Posebno upečatljivo: na hub strani, **HITS-hub** i **SALSA-hub** imaju **0% preklapanja u top-1000**, kao i HITS-hub i sirov out-degree. Ovo je konkretna, merljiva slika TKC efekta – HITS-ova iteracija je „zaključala” jednu gusto međusobno povezanu grupu čvorova sa umerenim (ne ekstremnim) izlaznim stepenom, potpuno odvojenu od čvorova koje bilo SALSA bilo prost broj izlaznih linkova smatraju dobrim hub-ovima.

5.3 Udeo „ugašenih” skorova

Slika 12 sumira udeo čvorova sa praktično-nula skorom ($< 10^{-10}$) za svih sedam razmatranih mera.




Figure 12: Udeo praktično-nula skorova po meri.

HITS drastično odudara (64% authority, 48% hub) od SALSA-e (7,2% / 0,06%), in-degree-a (7,2%), out-degree-a (0,06%) i PageRank-a (0%) – direktna potvrda H2 na nivou celog poređenja, ne samo unutar HITS-ove sopstvene validacije.

5.4 Test hipoteze H3

Da bismo proverili da li je nalaz iz prethodne sekcije (HITS skoro nekorelisan sa SALSA-om i PageRank-om) artefakt HITS-ovog masovnog „gašenja” skorova, korelacije smo ponovo izraču-

nali *isključivo* nad čvorovima kojima HITS dodeljuje ne-trivijalan (nenula) authority skor (36,1% čvorova):

- Spearman(HITS-authority, SALSA-authority) = 0,198 (naspram $-0,017$ bez maske),
- Spearman(HITS-authority, PageRank) = $-0,107$ (naspram $-0,068$ bez maske),
- Spearman(HITS-hub, SALSA-hub) = 0,411 (naspram 0,130 bez maske).

Korelacija ostaje niska (SALSA) ili negativna (PageRank) i nakon isključivanja „ugašenih” čvorova – **nalaz nije artefakt. H3 je time potvrđena**, i to znatno izraženije nego što je pretpostavka glasila: HITS-ovo rangiranje je, čak i među čvorovima koje sam HITS smatra „bitnim”, suštinski drugačije od SALSA-inog i PageRank-ovog rangiranja istih čvorova.

6 Zaključak

6.1 Sažetak nalaza po hipotezama

Table 3: Sažetak testiranih hipoteza.

Hipoteza	Tvrdnja	Status i ključna brojka
H1	SALSA authority $\propto$ in-degree na jednoj komponenti	Potvrđena (nijansirano): egzaktno (0,00 razlika) na test-grafu jedne komponente; $\rho = 0,79$ na stvarnom grafu
H2	HITS „gasi” čvorove van dominantne komponente više od SALSA-e/PageRank-a	Potvrđena: HITS 64% (authority) / 48% (hub) ugašeno naspram SALSA 7,2%/0,06%, PageRank 0%
H3	HITS i SALSA daju međusobno slabo korelisana rangiranja, uprkos istom grafu	Potvrđena, izraženije od očekivanog: $\rho(\text{HITS-aut}, \text{SALSA-aut}) = -0,02$; hub top-1000 preklapanje = 0%

6.2 Diskusija

Glavni nalaz ovog rada je da **SALSA daje „razumniji” link-based signal od HITS-a**: SALSA-authority je umereno do jako korelisana i sa PageRank-om i sa in-degree-om – dve nezavisne, intuitivno razumne mere važnosti čvora – dok je HITS suštinski nekorelisana sa obe, uprkos radu nad potpuno istim ulaznim grafom kao SALSA. Ovaj nalaz je robustan na isključivanje HITS-ovih „ugašenih” čvorova (sekcija 5), i naročito je izražen na hub strani, gde HITS i SALSA (kao i HITS i sirov out-degree) dele nula posto svojih top-1000 čvorova.

Veza sa referentnim radom. Najork [6] je na osnovu 28.043 upita i ljudskih relevance labela pokazao da SALSA kao izolovana karakteristika bitno nadmašuje HITS po IR metrikama (MAP, MRR, NDCG). Mi nemamo relevance labele te ne možemo direktno reprodukovati te metrike, ali naš nalaz – SALSA visoko korelisana sa PageRank-om/in-degree-om, koji su nezavisne, razumne mere kvaliteta; HITS suštinski nekorelisana sa bilo kojom od njih – je **kvalitativno konzistentan i komplementaran** sa njihovim: bez obzira na to da li HITS-ovo rangiranje poboljšava kvalitet pretrage, ono se sistemski razlikuje od svih ostalih razmatranih mera, na način koji se uklapa u poznatu kritiku HITS-a preko „tightly knit community” (TKC) efekta [3].

Ograničenja. Primena HITS-a i SALSA-e je globalna, a ne query-dependent kao u originalnim radovima – ovo je namerno pojednostavljeno diktirano formulacijom teme i nedostatkom skupa upita/rezultata pretrage, ali znači da naši rezultati nisu direktno uporedivi sa IR metrikama iz [6, 7]. Takođe, SALSA-ina numerička konvergencija na stvarnom grafu je spora (sekcija 4); rangiranje se pritom stabilizuje znatno pre pune numeričke konvergenije, što je posebno provereno i iskorišćeno.

6.3 Zaključak

Implementacijom sva tri algoritma nad istim grafom i njihovim sistematskim poređenjem preko rang-korelacije i preklapanja top- k skupova, potvrđene su sve tri postavljene hipoteze. Najznačajniji nalaz je da HITS, uprkos deljenju iste teorijske osnove i istog ulaznog grafa sa SALSA-om, proizvodi rangiranje koje je sa njim (i sa PageRank-om) praktično nekorelisano – nalaz koji direktno ilustruje TKC osetljivost HITS-a opisanu u originalnoj SALSA literaturi, i koji je u duhu glavnog zaključka referentnog Najork rada.

References

- [1] J. M. Kleinberg. *Authoritative sources in a hyperlinked environment*. Proc. 9th Annual ACM-SIAM Symposium on Discrete Algorithms, 1998.
- [2] J. M. Kleinberg. *Authoritative sources in a hyperlinked environment*. Journal of the ACM, 46(5):604–632, 1999.
- [3] R. Lempel, S. Moran. *The stochastic approach for link-structure analysis (SALSA) and the TKC effect*. Computer Networks and ISDN Systems, 33(1–6):387–401, 2000.
- [4] R. Lempel, S. Moran. *SALSA: The stochastic approach for link-structure analysis*. ACM Transactions on Information Systems, 19(2):131–160, 2001.
- [5] L. Page, S. Brin, R. Motwani, T. Winograd. *The PageRank citation ranking: Bringing order to the web*. Technical report, Stanford Digital Library Technologies Project, 1998.
- [6] M. Najork. *Comparing the Effectiveness of HITS and SALSA*. CIKM’07, 2007.
- [7] A. Borodin, G. O. Roberts, J. S. Rosenthal, P. Tsaparas. *Link analysis ranking: Algorithms, theory, and experiments*. ACM Transactions on Internet Technology, 5(1):231–297, 2005.
- [8] A. Broder, R. Kumar, F. Maghoul, P. Raghavan, S. Rajagopalan, R. Stata, A. Tomkins, J. Wiener. *Graph structure in the web*. Computer Networks, 33(1–6):309–320, 2000.