


PageRank, HITS i SALSA

Poređenje algoritama za rangiranje čvorova
u usmerenim grafovima

Nenad Dobrosavljević

Matematički fakultet, Univerzitet u Beogradu

Naučno izračunavanje, 2025/26.



Rangiranje čvorova u velikim usmerenim grafovima

- Odgovara na pitanje: **koji su čvorovi važniji od drugih?**
- Primer: **veb-graf**
 - čvor = veb-stranica
 - grana $u \rightarrow v$ = stranica u sadrži link ka stranici v

Tri algoritma

implementirani od nule, nad istim grafom

PageRank

jedan skor po čvoru

verovatnoća da se slučajni korisnik nalazi na stranici

HITS

authority i **hub**

authority = dobar izvor; hub
= dobro upućuje na izvore

SALSA

authority i **hub**

kombinuje HITS i PageRank
preko stohastičkih šetnji

Cilj projekta

- Implementirati PageRank, HITS i SALSA nad **istim** usmerenim grafom
- Uporediti dobijena **rangiranja**

Zašto ne standardne IR metrike?

Nemamo upite ni ljudski ocenjene relevantne rezultate (ground truth) $\Rightarrow$ rangiranja poredimo **direktno**, međusobno.

Kako poredimo rangiranja?

1. **Rang-korelacija** (Spearman ρ , Kendall τ) – koliko slično dva algoritma rangiraju sve čvorove
2. **Top- k preklapanje** – koliko istih čvorova je među k najboljih
3. **Udeo „ugašenih” čvorova** – skor $< 10^{-10}$

Istraživačke hipoteze

H1

SALSA authority $\sim$ in-degree, **SALSA hub** $\sim$ out-degree

H2

HITS „gasi” (skor ≈ 0) mnogo više čvorova nego PageRank i SALSA

H3

HITS i SALSA, iako rade nad istim grafom, mogu dati slabo korelisana rangiranja

PageRank

slučajni šetač na grafu

$$R(u) = \frac{1-d}{n} + d \sum_{v \rightarrow u} \frac{R(v)}{\text{out}(v)}, \quad d = 0,85$$

- 85% – prati slučajan link 15% – teleportacija
- Teleportacija $\Rightarrow$ svaki čvor može dobiti nenulti skor
- Dangling čvor (out-degree= 0): masa se ravnomerno redistribuirati

HITS

uzajamno pojačavanje hub i authority skorova

$$\mathbf{A}'(\mathbf{v}) = \sum_{u \rightarrow v} \mathbf{H}(\mathbf{u}), \quad \mathbf{H}'(\mathbf{u}) = \sum_{u \rightarrow v} \mathbf{A}(\mathbf{v})$$

- dobar **hub** → pokazuje na dobre **authority**-je
- dobar **authority** → na njega pokazuju dobri **hub**-ovi
- power-iteracija konvergira ka **jednom** dominantnom pravcu $\Rightarrow$ motivacija za H2

SALSA

dve nezavisne stohastičke šetnje na hub-authority grafu

$$H'(u) = \sum_{u \rightarrow v} \sum_{w \rightarrow v} \frac{H(w)}{\text{in}(v) \cdot \text{out}(w)},$$

$$A'(u) = \sum_{v \rightarrow u} \sum_{v \rightarrow w} \frac{A(w)}{\text{out}(v) \cdot \text{in}(w)}$$

- **hub-šetnja**: hub $w \rightarrow$ nasumičan **authority**-sused v (verovatnoća $1/\text{out}(w)$)
 $\rightarrow$ nasumičan **hub** u koji takođe pokazuje na v (verovatnoća $1/\text{in}(v)$)
- **authority-šetnja** je simetrična, u obrnutom smeru

Ključno svojstvo (jedna povezana komponenta)

$$A(u) \propto \text{in}(u),$$


$$H(u) \propto \text{out}(u)$$

Skup podataka

web-Stanford graf

Karakteristika	Vrednost
Broj čvorova	281.903
Broj grana	2.312.497
Prosečan in/out-degree	8,2
Maksimalni in-degree	38.606
Maksimalni out-degree	255
Dangling čvorovi (out-degree= 0)	0,06%
Čvorovi sa in-degree= 0	7,2%
Najveća slabo pov. komponenta (WCC)	90,6%
Najveća jako pov. komponenta (SCC)	53,4%

Distribucija stepena čvorova




Ulazni i izlazni stepen čvorova, log-log skala.

- **Power-law** struktura – graf **nije** jedna povezana celina („bowtie”) → bitno za H1, H2


PageRank

rezultati i validacija



Konvergencija power-iteracije.


■ **118 iteracija** do konvergencije – validacija (networkx): Spearman $\rho = 0,999997$



Top-10 čvorova po skoru.

HITS

konvergencija i validacija




Konvergencija power-iteracije.

- Konvergira nakon **97 iteracija** – validacija (networkx): Spearman $\rho \approx 0,9999$

HITS gasi čvorove

test hipoteze H2




Udeo „ugašenih“ čvorova.

- 7,2% čvorova ima $\text{in-degree} = 0 \Rightarrow$ **authority** mora biti 0
- Ali HITS praktično gasi: **63,9% authority** / **47,7% hub** skorova
- Power-iteracija se koncentriše na dominantan pravac
- $\Rightarrow$ **H2 potvrđena**

HITS

top-10 i Tightly Knit Community efekt




Top-10 čvorova po authority i hub skoru.

- Top-10 **hub** skorovi **skoro identični** ⇒ „Tightly Knit Community” efekt: gusto povezana grupa sama sebe pojačava

SALSA

konvergencija




Konvergencija power-iteracije.

- Numerički **sporija** ($L1 \approx 2 \times 10^{-5}$ i posle 2.500 iteracija) – ali **rangiranje** stabilno mnogo ranije, top-10 **authority** identičan

SALSA

test hipoteze $H1$




Authority vs. in-degree i hub vs. out-degree.

■ **authority** vs. in-degree $\rho=0,788$, **hub** vs. out-degree $\rho=0,764 \Rightarrow H1$ potvrđena, nijansirano

SALSA

top-10 authority i hub




Top-10 čvorova po authority i hub skoru.

- Najbolji **authority** čvorovi **nisu nužno** isti kao najbolji **hub**-ovi – SALSA jasno razdvaja uloge

Poređenje algoritama

rang-korelacije




Spearman ρ između svih razmatranih mera.

- PageRank, **SALSA-authority**, in-degree koreliraju jako ($\rho=0,59-0,79$) – HITS se izdvaja: $\rho \approx -0,02$ do $-0,07$

Poređenje

Poređenje algoritama

top-k preklapanje




Preklapanje top-100 skupova čvorova.

- top-100: **SALSA-authority vs. in-degree = 95%** – top-1000: **HITS-hub vs. SALSA-hub = 0%**

Poređenje

Poređenje algoritama

konačna provera H2 i H3



Udeo praktično-nula skorova po meri.

- HITS: **64% aut.** / **48% hub** ugašeno naspram SALSA 7,2%/0,06% – i dalje niska korelacija ⇒ **nije artefakt**

Zaključak

sažetak hipoteza

Hipoteza	Status
H1	✓ potvrđena (nijansirano) – $\rho = 0,79$ na stvarnom grafu
H2	✓ potvrđena – HITS 64%/48% naspram SALSA 7,2%/0,06%
H3	✓ potvrđena – $\rho \approx -0,02$, top-1000 preklapanje = 0%

Zaključak

glavni nalaz i ograničenja

Glavni nalaz

SALSA daje signal **konzistentniji** sa PageRank-om i in-degree-om; HITS je od njih praktično nekorelisan.

- Ne tvrdimo da je SALSA „bolja za pretragu” – nemamo relevance labele
- Ograničenje: HITS i SALSA primenjeni globalno, ne query-dependent
- Ograničenje: SALSA numerički sporo konvergira (ali rangiranje mnogo ranije)

Hvala na pažnji

Pitanja?

